



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение
высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ «Информатика и системы управления»

КАФЕДРА «Программное обеспечение ЭВМ и информационные технологии»

РАСЧЕТНО-ПОЯСНИТЕЛЬНАЯ ЗАПИСКА
К ВЫПУСКНОЙ КВАЛИФИКАЦИОННОЙ РАБОТЕ
НА ТЕМУ:

«Графовая языковая модель для решения задачи машинного перевода»

Студент	ИУ7-81Б		Н. А. Беляев
	(группа)	(подпись)	(инициалы, фамилия)
Руководитель ВКР			Ю. В. Строганов
		(подпись)	(инициалы, фамилия)
Нормоконтролер			
		(подпись)	(инициалы, фамилия)

2026 год

РЕФЕРАТ

Расчетно-пояснительная записка 46 страниц, 12 рисунков, 6 таблиц, 38 источников, 4 приложения

Ключевые слова: МАШИННЫЙ ПЕРЕВОД, ЯЗЫКОВАЯ МОДЕЛЬ, СЕМАНТИЧЕСКАЯ СЕТЬ, ГРАФОВАЯ СУБД, ОМОНИМИЯ, ДЕТЕРМИНИРОВАННЫЙ ПЕРЕВОД.

Цель работы – разработка графовой языковой модели для решения задачи машинного перевода.

В аналитическом разделе введены основные понятия предметной области машинного перевода, рассмотрены и сравнены существующие методы машинного перевода и программные решения для обработки графовых данных, постановка задачи формализована в виде функциональной модели.

В конструкторском разделе спроектирована структура графовой языковой модели и метод машинного перевода с ее применением.

В технологическом разделе описаны программные средства реализации метода, приведена реализация основных алгоритмов, инструкция по развертыванию и использованию ПО.

В исследовательском разделе проведено исследования качества перевода разработанного метода для различных предметных доменов.

В результате выполнения работы разработана графовая языковая модель для решения задачи машинного перевода и метод перевода с ее применением.

СОДЕРЖАНИЕ

РЕФЕРАТ	5
ВВЕДЕНИЕ	7
1 Аналитический раздел	8
1.1 Определения и термины задачи машинного перевода	8
1.1.1 Этапы разбора текста на естественном языке	9
1.1.2 Семантическая сеть	11
1.2 Языковые модели, применяемые для решения задачи машинного перевода	12
1.2.1 Машинный перевод на основе правил	12
1.2.2 Машинный перевод на основе примеров	13
1.2.3 Статистический машинный перевод	14
1.2.4 Нейронный машинный перевод	15
1.2.5 Сравнительный анализ рассмотренных методов	17
1.3 Существующие программные решения для обработки графовых данных	18
1.3.1 СУБД PostgreSQL	18
1.3.2 СУБД Gel	19
1.3.3 СУБД Neo4j	19
1.3.4 СУБД ArangoDB	19
1.3.5 СУБД Ontotext GraphDB	19
1.3.6 СУБД Janus Graph	19
1.3.7 Сравнительный анализ рассмотренных графовых СУБД	21
1.4 Формализованная постановка задачи	22
2 Конструкторский раздел	23
2.1 Семантическая сеть	23
2.2 Определение расстояния между вершинами в графе	24
2.3 Структура графовой языковой модели	25
2.4 Метод машинного перевода на основе графовой языковой модели	26
2.4.1 Алгоритм разбиения входного предложения на токены	28

2.4.2	Алгоритм формирования подстрочного перевода . . .	29
2.4.3	Алгоритм выбора вершины в графе исходного языка	30
2.4.4	Анализ входного предложения	34
2.4.5	Изменение словоформ подстрочного перевода	34
2.5	Наполнение графовой языковой модели данными	35
3	Технологический раздел	36
3.1	Выбор средств реализации	36
3.2	Структура ПО	37
3.2.1	Руководство по разворачиванию ПО	38
3.2.2	Руководство по использованию ПО	38
4	Исследовательский раздел	39
4.1	Описание исследования	39
4.2	Исследование № 1. Детерминированность перевода	40
4.2.1	Постановка	40
4.2.2	Результаты	40
4.3	Исследование № 2. Корректность перевода терминов	42
4.3.1	Постановка	42
4.3.2	Результаты	42
4.3.3	Анализ результатов	43
	ЗАКЛЮЧЕНИЕ	44
	ПРИЛОЖЕНИЕ А	45
	ПРИЛОЖЕНИЕ Б	46
	СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	45

ВВЕДЕНИЕ

На 2026 год рынок машинного перевода оценивается в 1.26 миллиарда долларов, согласно прогнозу к 2031 году он увеличится вдвое, составив 2.19 млрд. долларов [1].

Порядка 56% решений в области машинного перевода основаны на нейронных моделях [1], при этом такие модели обеспечивают корректный перевод лишь в порядке половины случаев [2].

Цель работы – разработка графовой языковой модели для решения задачи машинного перевода.

Для достижения поставленной цели необходимо решить следующие задачи:

- 1) ввести основные термины и определения задачи машинного перевода, проанализировать существующие методы машинного перевода и программные методы для обработки графовых данных;
- 2) спроектировать метод машинного перевода на основе графовой языковой модели;
- 3) разработать ПО, реализующее спроектированный метод;
- 4) провести исследование качества результатов разработанного метода для различных предметных доменов.

1 Аналитический раздел

В данном разделе даны основные определения и описаны термины задачи машинного перевода. Классифицированы языковые модели, применяющиеся для решения задачи машинного перевода. Описаны существующие программные решения, применяемые для обработки графовых данных. Постановка задачи формализована в виде функциональной модели.

1.1 Определения и термины задачи машинного перевода

Язык – это набор символов, соглашений и правил, которые используются для предоставления информации [3].

Естественный язык – это язык, правила которого основываются на текущем употреблении без точного описания [3].

Машинный перевод – это процесс перевода текста с одного естественного языка на другой, реализуемый компьютером с возможным участием человека.

При машинном переводе человек может иметь разную степень участия [4]:

- 1) предредактирование – человек вручную подготавливает текст к научной обработке: убирает неоднозначные сочетания, упрощает исходные текст;
- 2) интерредактирование – человек вмешивается непосредственно в процесс перевод и разрешает сложившиеся сложные ситуации;
- 3) постредактирование – человек обрабатывает конечный результат машинного перевода и устраняет недочеты;

Любые из вышеперечисленных этапов могут быть применены к одному тексту одновременно. Перевод, выполняемый человеком с применением программы-помощника называется автоматизированным.

Для решения задачи обработки естественного языка применяются классические методы компьютерной лингвистики и методы машинного обучения, основанные на использовании языковых моделей [5].

Языковая модель – это искусственно создаваемое реальное или мысленное устройство, воспроизводящее, имитирующее языковое явление в упрощенном виде [6].

Единица обработки символьной последовательности языковой моделью называется токеном. Токеном может быть символ, часть слова, целое слово или группа слов. Отдельно выделяют токены, обозначающие начало и конец последовательности [7].

1.1.1 Этапы разбора текста на естественном языке

Самые большие возможности и высокое качество анализа текстов можно получить, проведя его полный анализ. Однако сложности, возникающие при создании подобного анализа таковы, что на практике до сих пор не реализованы все теоретические положения, разработанные на данный момент. Сложность анализа текста на естественном заключается в том, что текст эллиптичен, неполон и насквозь пронизан умолчаниями [3].

Процесс полного анализа текста на естественном языке состоит из четырёх последовательных этапов анализа, отображённых на рисунке 1.1.




Рисунок 1.1 – Процесс анализа текста на естественном языке

В таблице 1.1 перечислены выполняемые этапы анализа и цели каждого из них.

Таблица 1.1 – Классические этапы анализа текста на естественном языке

№	Анализ	Цель
1	Графематический	Выделить структурные элементы, определить границы предложений
2	Морфологический	Определить морфологические характеристики слов (число, род, падеж, ...)
3	Синтаксический	Определить связи между словами в тексте
4	Семантический	Определить смысл текста

Перед обработкой текста с помощью ЯМ все также необходимо выполнить этап его разбиения на токены, однако прочие этапы выполняются неявно. При использовании нейронных ЯМ добавляется предварительный этап получения векторных представлений токенов – этап построения эмбедингов. Эмбединг – это вектор, который является математическим представлением токена [8].

1.1.2 Семантическая сеть

Семантическая сеть – это информационная модель предметной области, представленная в виде ориентированного графа. Вершины графа содержат понятия, а ребра отображают семантические связи между ними. Семантическая близость терминов определена как расстояние между соответствующими им вершинами. На рисунке 1.2 показан пример семантической сети.




Рисунок 1.2 – Пример семантической сети

1.2 Языковые модели, применяемые для решения задачи машинного перевода

Выделяют следующие разновидности машинного перевода [4]:

- 1) машинный перевод на основе правил;
- 2) машинный перевод на основе примеров;
- 3) статистический машинный перевод;
- 4) нейронный машинный перевод.

1.2.1 Машинный перевод на основе правил

Методы машинного перевода на основе правил имеют в основе грамматические, синтаксические, морфологические и семантические закономерности языков перевода и оригинала. Данный подход включает три разные стратегии перевода:

- 1) системы пословного перевода;
- 2) трансферные системы;
- 3) интерлингвистические системы.

Перевод с помощью системы пословного перевода опирается на использование словаря, включающего в себя языковые соответствия. Моделирование функционирования всей языковой системы не предусмотрено.

Перевод с помощью трансферных систем является более продвинутым, требует информации о грамматической структуре языка оригинала и языка перевода. Перевод с помощью таких систем состоит из трех последовательных этапов:

- 1) анализ текста оригинала и определение его грамматической структуры;
- 2) перевод грамматической структуры языка оригинала в грамматическую структуру языка перевода;
- 3) генерация текста на языке перевода.

Интерлингвистические системы подразумевают перевод текста на языке оригинала в интерлингву – абстрактное, независящее от правил языка, представление текста. Затем из интерлингвы текст преобразуется в язык перевода. Интерлингвистические системы полностью независимы от грамматик языков при составлении абстрактного представления текста. Сложность метода заключается в определении и составлении интерлингвы.

Разрешение омонимии и неоднозначного перевода в системах на основе правил осуществляется явно: для каждого многозначного слова в словаре задаются правила выбора нужного значения в зависимости от контекста. Трансферные и интерлингвистические системы способны разрешать омонимию на основе грамматического и семантического анализа. Однако составление полного набора правил для покрытия всех случаев омонимии требует значительных трудозатрат экспертов предметной области и практически неосуществимо для широкого круга тематик [4].

1.2.2 Машинный перевод на основе примеров

Система машинного перевода на основе примеров требует наличия двуязычных параллельных корпусов, содержащих пары предложений. В систему вносится большое количество предложений-примеров и процесс перевода производится по аналогии с этими примерами. Система машинного перевода на основе примеров основана на представлении о том, что человек-переводчик не проделявает лингвистический анализ при переводе, а пользуется аналогией: разбивает предложение на фразы, переводит их, а затем составляет из полученных фрагментов предложение, соответствующее грамматическим и лексическим нормам языка перевода.

Разрешение омонимии и неоднозначного перевода в системах на основе примеров происходит неявно: если в параллельном корпусе достаточно примеров, содержащих многозначное слово в разных контекстах, система способна выбрать нужный перевод по аналогии. Однако при недостаточном количестве примеров для конкретного контекста омонимия не разрешается корректно. Данный метод не предоставляет механизма явного управления разрешением неоднозначности [4].

1.2.3 Статистический машинный перевод

Статистический машинный основан на поиске наиболее вероятного перевода предложения с использованием данных, полученных из параллельного корпуса в результате обучения.

Перевод формулируется как задача поиска наиболее вероятного текста на целевом языке $\hat{e}$ для исходного текста f согласно формуле (1.1):

$$\hat{e} = \arg \max_e P(e \mid f) = \arg \max_e P(f \mid e) \cdot P(e), \quad (1.1)$$

где $P(f \mid e)$ — модель перевода, $P(e)$ — языковая модель целевого языка.

К статистическим моделям машинного перевода относятся модели на основе n -грамм: вероятность следующего слова w_{i+1} определяется предшествующим кортежем слов длины $n - 1$ согласно формуле (1.2):

$$P(w_{i+1} \mid w_{i-n+1} \dots w_i) = \frac{\text{count}(w_{i-n+1} \dots w_{i+1})}{\text{count}(w_{i-n+1} \dots w_i)}, \quad (1.2)$$

где $\text{count}(x)$ — число вхождений подстроки x в корпус C .

Затраты по памяти на хранение n -грамм составляют $O(|V|^n)$, где $|V|$ — размер словаря. Статистические модели машинного перевода не учитывают грамматические правила языков, для получения грамматически корректного перевода требуется дополнительная обработка текста. Статистические модели не способны учитывать сколь угодно большой контекст для определения перевода очередного термина. Например, модель на основе n -грамм учитывает лишь $n - 1$ предшествующее текущему слово [7].

1.2.4 Нейронный машинный перевод

Методы на основе нейронного машинного перевода используют нейронные сети в качестве систем перевода. Вне зависимости от конкретной архитектуры, нейронная сеть имеет внутреннее состояние – множество весов w . Обучение модели на основе нейронной сети заключается в определении параметров w сети путем минимизации некоторой функции ошибки L_w на основе параллельного корпуса текстов.

Базовая модель нейронного машинного перевода использует рекуррентные нейронные сети и состоит из двух последовательных блоков: энкодера и декодера. Задача энкодера – вычислить соответствующий входной последовательности токенов контекстный вектор. Энкодер обрабатывает входную последовательность последовательно, токен за токеном, на каждом шаге обновляя вектор внутреннего состояния. Образованный на последнем шаге работы энкодера вектор внутреннего состояния называется контекстным вектором. Контекстный вектор подается на вход декодеру, который вычисляет выходную последовательность токенов, составляющую перевод исходного предложения.

Модель на основе энкодера и декодера из рекуррентных нейронных сетей позволяет учитывать больший контекст при переводе терминов, нежели статистические модели, за счет использования контекстного вектора, содержащего информацию о входной последовательности. Тем не менее, такая модель не способна использовать сколь угодно большой контекст. Например, при размере контекстного вектора $p = 30$ модель начинает деградировать с увеличением длины входной последовательности от 20-ти токенов и более [9]. Данный эффект называется затуханием контекста.

Для решения проблемы затухания контекста используются модели с механизмом внимания. Без использования механизма внимания декодер располагал только одним контекстным вектором, получаемым на выходе энкодера – вся информация о входной последовательности сжата в вектор фиксированного размера. При использовании механизма внимания декодер использует информацию о всех скрытых состояниях энкодера, так как контекстный вектор вычисляется по формуле (1.3) как взвешенная сумма

всех внутренних состояний декодера:

$$c_j = \sum_{i=1}^n a_{ji} h_i, \quad (1.3)$$

где:

- c_j — контекстный вектор на шаге j декодера;
- h_i — скрытое состояние энкодера на шаге i ;
- a_{ji} — вес внимания, определяющий вклад состояния h_i при формировании c_j .

Данный подход решает проблему затухания контекста, однако последовательная обработка входной последовательности делает метод вычислительно неэффективным.

Архитектура «Трансформер» уходит от рекуррентных слоёв в пользу механизма многоголового самовнимания, что позволяет обрабатывать все токены параллельно [10]. Внимание вычисляется согласно формуле (1.4):

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_h}}\right) V, \quad (1.4)$$

где:

- Q — матрица запросов;
- K — матрица ключей;
- V — матрица значений;
- d_h — размерность пространства ключей.

Модели на основе нейронного машинного перевода обеспечивают наилучшее качество перевода в общем случае, однако склонны к галлюцинациям при недостаточном представлении предметной области в обучающих данных [11]. Результат нейронного машинного перевода недетерминирован. Обучение крупных нейронных моделей обходится в миллионы долларов [12].

Нейронные модели способны неявно разрешать омонимию и неоднозначный перевод за счёт широкого контекстного окна и механизма внимания, однако данный процесс является недетерминированным.

1.2.5 Сравнительный анализ рассмотренных методов

В таблице 1.2 представлено сравнение рассмотренных групп методов машинного перевода (МП).

Таблица 1.2 – Сравнение групп методов машинного перевода

	МП на основе правил	МП на основе примеров	Статист. МП	Нейронный МП
Детерминированность	+	+	+	–
Отказ при отсутствии данных	–	±	–	–
Тип токена	Морфема	Слово / группа слов	Слово / подслово	Подслово
Структура	Набор правил	Паралл. корпус	Паралл. корпус	Паралл. корпус
Трудоёмкость наполнения	Низкая	Низкая	Средняя	Низкая
Трудоёмкость подготовки данных	Высокая	Средняя	Средняя	Низкая

1.3 Существующие программные решения для обработки графовых данных

Семантическая сеть терминов языка представима в виде графа. Вершины графа содержат термины, а рёбра отражают связь между ними.

Для программной обработки графовых структур широко применяются следующие библиотеки:

- NetworkX – библиотека языка Python для создания, анализа и визуализации графов. Предоставляет реализации алгоритмов на графах [13];
- igraph – высокопроизводительная библиотека для анализа графов, доступная для Python, R и C. Реализует широкий набор алгоритмов и эффективно обрабатывает графы с миллионами вершин [14];
- GraphX – компонент платформы Apache Spark для распределённой обработки графовых данных. Предназначен для масштабируемого анализа крупных графов в распределённых вычислительных кластерах [15];
- DGL – библиотека для построения и обучения графовых нейронных сетей. Используется для задач машинного обучения на графах, в том числе для получения эмбедингов вершин [16].

Ниже рассмотрены существующие графовые системы управления базами данных (СУБД).

1.3.1 СУБД PostgreSQL

PostgreSQL – это реляционная СУБД, реализующая гарантии ACID [17], [18]. Данные хранятся в таблицах, графовые структуры реализуются через операции JOIN и рекурсивные табличные выражения (CTE). Расширение pgvector добавляет тип данных VECTOR и операции вычисления расстояний между векторами [19]. Предельная размерность типа VECTOR – 2000 измерений. Именованные рёбра с произвольными атрибутами требуют нескольких вспомогательных таблиц, что усложняет запросы к графу.

1.3.2 СУБД Gel

Gel – графово-реляционная СУБД, расширяющая PostgreSQL [20]. Поддерживает графовую модель хранения данных и язык Edge Query Language (EQL). Наследует типы и расширения PostgreSQL, в том числе pgvector с ограничением размерности 2000.

1.3.3 СУБД Neo4j

Neo4j – графовая СУБД, реализующая модель Property Graph [21]. Данные представлены узлами и рёбрами; и узлы, и рёбра поддерживают произвольные именованные свойства и метки. Именованные метки рёбер позволяют непосредственно кодировать типы семантических отношений без дополнительных таблиц. Язык запросов Cypher обеспечивает выразительный синтаксис для обхода графа. Поддерживает тип VECTOR и векторные индексы.

1.3.4 СУБД ArangoDB

ArangoDB – мультимодальная СУБД, поддерживающая документоориентированную и графовую модели хранения данных [22]. Данные хранятся в виде коллекций документов, рёбра содержат идентификаторы вершин. Для запросов используется язык AQL. В четвёртой версии добавлена поддержка эмбедингов без ограничения размерности.

1.3.5 СУБД Ontotext GraphDB

Ontotext GraphDB – графовая СУБД, хранящая данные в формате триплетов (субъект, предикат, объект) стандарта RDF [23]. Поддерживает язык запросов SPARQL и онтологии в формате OWL. Предикат триплета выполняет роль именованного ребра, что делает данную СУБД естественным выбором для хранения лингвистических онтологий.

1.3.6 СУБД Janus Graph

Janus Graph – графовая СУБД с открытым исходным кодом [24], основанная на распределённой СУБД Apache Cassandra [25]. Поддерживает язык графовых запросов Gremlin [26] и тип данных VECTOR для хранения эмбедингов.

1.3.7 Сравнительный анализ рассмотренных графовых СУБД

В таблице 1.3 приведен сравнительный анализ рассмотренных графовых СУБД.

Таблица 1.3 – Сравнение СУБД для хранения графовых данных

Критерий	PostgreSQL	Gel	Neo4j	ArangoDB	Ontotext
Модель данных	Реляционная	Граф.-реляц.	Графовая	Мульти-модальная	Трипл.
Метки ребер	–	Огр.	+	+	+
Язык запросов	SQL	SQL, EQL	Cypher	AQL	SPARQL
Векторный индекс	+	+	+	+	–
Открытый код	+	+	–	+	+

1.4 Формализованная постановка задачи

На рисунке 1.3 приведена формализованная постановка задачи в виде диаграммы IDEF0 нулевого уровня.




Рисунок 1.3 – Формализованная постановка задачи в нотации IDEF0 нулевого уровня

На разрабатываемый метод наложены дополнительные ограничения:

- 1) язык X – английский, язык Y – русский;
- 2) наполнение модели происходит вручную.

Вывод

В данном разделе введены основные определения задачи машинного перевода, рассмотрены существующие методы машинного перевода и программные решения для обработки графовых данных, постановка задачи формализована в виде функциональной модели.

2 Конструкторский раздел

В разделе описана структура графовой языковой модели для решения задачи машинного перевода, приведены алгоритмы перевода с ее использованием.

2.1 Семантическая сеть

Семантическая сеть языка Σ_u формализована в виде взвешенного ориентированного графа $U = (V_u, E_u)$, где V_u – множество вершин, E_u – множество связей между вершинами. Вершина $v \in V_u$ есть кортеж вида (l_u, q_u) , где:

- $l_u \in \Sigma_u$ – токен;
- $q_l \in \{0, 1, 2, \dots\}$ – индекс омонимии.

Термин может быть составным, в таком случае l_u – последовательность лемм всех его частей. Индекс омонимии служит для того, чтобы различать вершины семантической сети, которые содержат омонимы.

Ребро $e \in E_u$ есть кортеж вида (v_i, v_j, m, w) , где:

- $v_i, v_j \in V_u$ – вершины, между которыми установлена связь;
- $m \in M$ – метка типа отношения;
- $w(m) \in [0, 1]$ – вес отношения.

Множество M содержит метки возможных отношений между терминами:

- СВМ – совместная встречаемость;
- ПРИЧ – причинно-следственная связь;
- ЧЦ – отношение «часть–целое»;
- ОЧ – отношение «общее–частное».

Вес ребра зависит от его типа.

2.2 Определение расстояния между вершинами в графе

Стоимость прохождения по ребру определяется весом $w(t)$, зависящим от его типа.

Расстояние $d(v_i, v_j)$ между вершинами v_i, v_j есть минимальная стоимость пути от одной вершины до другой на неориентированной проекции графа U , определённая формулой (2.1):

$$d(v_i, v_j) = \min \sum_{w_k \in P_{i,j}} w_k, \quad (2.1)$$

где $P_{i,j}$ — множество меток ребер, образующих путь от v_i до v_j .

Максимальное число рёбер, образующих путь, ограничено параметром $D_{\max}$. Вершина v_i считается недостижимой из v_j , если пути не существует или все пути длиннее $D_{\max}$ рёбер. Для вычисления расстояния используется алгоритм Дейкстры с ограничением глубины.

2.3 Структура графовой языковой модели

Графовая модель для решения задачи машинного перевода есть четверка (X, Y, R, W) , где:

- X, Y – графы терминологических отношений языков Σ_x и Σ_y соответственно;
- R – множество отношений перевода между вершинами графов X и Y ;
- W – кортеж весов, соответствующих меткам типов рёбер.

Между вершинами $v_x \in X$, $v_y \in Y$ установлено отношение перевода $r \in R$, если лемма $l_y \in v_y$ есть перевод леммы $l_x \in v_x$.

На рисунке 2.1 изображен пример заполненной модели, в частности продемонстрирована омонимия термина root и неоднозначный перевод термина log. Красным отмечены вершины графа X , синим – графа Y , черным – отношения перевода.



Рисунок 2.1 – Пример заполненной модели

2.4 Метод машинного перевода на основе графовой языковой модели

Метод состоит из четырех этапов.

- 1) разбиение предложения на токены.
- 2) формирование подстрочного перевода.
- 3) синтаксический и морфологический анализ входного предложения.
- 4) изменение словоформ подстрочного перевода в соответствии с синтаксической структурой входного предложения.

На рисунке 2.2 изображена функциональная модель предлагаемого метода в нотации IDEF0 первого уровня.



Рисунок 2.2 – Функциональная модель предлагаемого метода в нотации IDEF0 первого уровня

2.4.1 Алгоритм разбиения входного предложения на токены

На рисунке 2.3 изображена схема алгоритма разбиения входного предложения на токены.




Рисунок 2.3 – Алгоритм разбиения входного предложения на токены

Алгоритм принимает на вход предложение на исходном языке. Знаки препинания заменяются пробельными символами, после чего предложение

разбивается на отдельные слова. Каждое слово лемматизируется – приводится к словарной форме. Далее следует этап распознавания терминов, начиная с самых длинных составных и заканчивая односложными. Термин может быть распознан, если модель содержит вершину с ним, омонимия на данном этапе игнорируется.

2.4.2 Алгоритм формирования подстрочного перевода

На рисунке 2.4 изображена схема алгоритма формирования подстрочного перевода терминов.




Рисунок 2.4 – Алгоритм формирования подстрочного перевода

2.4.3 Алгоритм выбора вершины в графе исходного языка

На рисунке 2.5 изображена схема алгоритма выбора вершины, соответствующей лемме в графе исходного языка.



Рисунок 2.5 – Алгоритм выбора вершины в графе исходного языка

Если у леммы l_x нет омонимов, то вершина определяется однозначно. В противном случае среди множества вершин, содержащих омонимы l_x , необходимо определить истинную v_{target} .

Контекстное окно – множество C_l соседних к l_x лемм в пределах L позиций. Контекстные вершины – множество вершин C_x , соответствующих леммам C_l .

Идея алгоритма: среди всех вершин, содержащих омонимы l_x , истиной является та, функция близости до которой от контекстных вершин C_x больше. Функция близости определяется по формуле (4.2):

$$N(v, C_x) = \sum_{v_j \in C_x} \frac{1}{d(v, v_j) + 1}, \quad (2.2)$$

где:

- $d(v, v_j)$ — расстояние между вершинами v и v_j в графе, определённое формулой (2.1);
- C_x — множество контекстных вершин.

Разрешение омонимии для термина «root», предложения «Root OS user has highest privilege» с $L = 1$ для модели, изображенной на рисунке 2.6.




Рисунок 2.6 – Пример семантической сети

Контекстное окно «root» – термин «os user», для «root» имеется две вершины-претендента. Для вершины с индексом омонимии 1 функция близости до вершины, содержащей термин «os user», определена по формуле (2.3):

$$N_1(v(root_1), C_x = \{v_{os\ user}\}) = \frac{1}{5 \cdot w(\text{ЧЦ}) + 2 \cdot w(\text{ОЧ}) + 1}. \quad (2.3)$$

Для вершины с индексом омонимии 2 функция близости до вершины, содержащей термин «os user», определена по формуле (2.4):

$$N_2(v(root_2), C_x = \{v_{os\ user}\}) = \frac{1}{w(\text{ОЧ}) + 1}. \quad (2.4)$$

Истинной вершиной является v_{root_2} , так как $N_1 \leq N_2$.

2.4.4 Анализ входного предложения

С помощью библиотек для обработки естественного языка выполняется синтаксический и морфологический анализ входного предложения. Для каждого слова входного предложения определяется род, число, падеж. На основе структуры входного предложения формируется синтаксическое дерево, описывающее отношения между словами в предложении.

2.4.5 Изменение словоформ подстрочного перевода

В результате анализа входного предложения о каждом слове входного предложения известен:

- род;
- число;
- падеж;
- время;
- синтаксическая роль.

Изменения словоформы элемента подстрочного перевода происходит таким образом, чтобы восстановить перечисленные выше характеристики слова исходного предложения.

2.5 Наполнение графовой языковой модели данными

Наполнение модели производится специалистом в ручном режиме. При этом необходимо определить:

- веса типов отношений между терминами;
- множество вершин;
- множество отношений между терминами в рамках языка;
- множество отношений перевода.

3 Технологический раздел

В данном разделе приведен перечень выбранных средств для программной реализации метода, описаны основные модули разработанного программного обеспечения, описаны инструкции для развертывания и использования программного обеспечения.

3.1 Выбор средств реализации

Для реализации программного обеспечения выбраны следующие инструменты:

- язык программирования Python [27];
- графовая СУБД Neo4j [28];
- инструмент контейнеризации Docker [29].

При разработке использовались библиотеки:

- flask для реализации веб-интерфейса [30];
- rymorphy3, lemmatizer, spacy для программной обработки естественного языка [31—33];
- neo4j для взаимодействия с СУБД Neo4j [34].

Данный набор инструментов и библиотек позволяет решить поставленную задачу по программной реализации метода.

3.2 Структура ПО

На рисунке 4.2 представлена структура разработанного ПО.




Рисунок 3.1 – Структура ПО

3.2.1 Руководство по развертыванию ПО

Системные требования, необходимые для развертывания ПО:

- операционная система Linux;
- интерпретатор языка программирования Python;
- программа для контейнеризации Docker.

Для развертывания ПО на локальной машине необходимо:

- установить библиотеки, перечисленные в файле «requirements.txt»;
- запустить СУБД Neo4j в Docker-контейнере.

3.2.2 Руководство по использованию ПО

Разработанное ПО предоставляет пользователю следующие функции в графическом интерфейсе:

- выполнение перевода предложения с английского языка на русский;
- наполнение модели данными;
- просмотр содержимого модели.

4 Исследовательский раздел

В разделе описана постановка и результаты исследований разработанного метода. Была исследована детерминированность и частота корректности перевода разработанной модели и нейронной модели GPT-4 [35] для различных предметных доменов.

Цель – исследовать детерминированность перевода и корректность перевода терминов реализованной модели для различных предметных доменов, сравнить полученные показатели с нейронной моделью GPT-4.

4.1 Описание исследования

Проведенные исследования охватывают три предметных домена. В таблице 4.1 приведены названия доменов и соответствующий процент публикаций технических статей за 2021-2026г.

Таблица 4.1 – Рассматриваемые предметные домены

№	Предметный домен	Процент публикаций среди технических публикаций за 2021–2026 г.
1	Информационные технологии (ИТ)	19%
2	Строительство	8%
3	Аэрокосмическая отрасль	3%

В каждом исследовании результаты разработанной графовой языковой модели (ГЯМ) сравниваются с результатами нейронной языковой модели (НЯМ) модели GPT-4. Число запусков на одних входных данных принято равным $N = 10$.

Терминология для соответствующих предметных доменов была взята из соответствующих англо-русских словарей [36], [37], [38].

4.2 Исследование № 1. Детерминированность перевода

4.2.1 Постановка

Для указанных предметных доменов исследовать зависимость показателя детерминированности перевода в зависимости от длины предложения. Сравнить с нейронной моделью GPT-4.

Показатель детерминированности D определён по формуле (4.1):

$$D = \frac{\text{freq}(\text{mode}(Y_1, \dots, Y_N))}{N}, \quad (4.1)$$

где

- N – число запусков на одних входных данных;
- Y_i – результат перевода при i -м запуске;
- $\text{mode}(\cdot)$ – мода;
- $\text{freq}(\cdot)$ – частота моды.

При $D = 1$ модель полностью детерминирована: все N запусков дают одинаковый результат.

4.2.2 Результаты

Обозначения столбцов:

- D_{Γ} – значение показателя детерминированности для разработанной графовой языковой модели;
- $D_{\text{Н}}$ – значение показателя детерминированности для нейронной модели GPT-4.

Таблица 4.2 – Результаты исследования № 1. Детерминированность перевода

Длина предложения, шт. слов	ИТ		Строительство		Аэрокосмическая отрасль	
	D_{Γ}	D_{Π}	D_{Γ}	D_{Π}	D_{Γ}	D_{Π}
3	1	0,8	1	0,7	1	0,7
5	1	0,7	1	0,7	1	0,5
7	1	0,7	1	0,5	1	0,4
9	1	0,4	1	0,6	1	0,3
11	1	0,5	1	0,6	1	0,3

На рисунке 4.2 результаты исследования представлены в виде гистограммы.




Рисунок 4.1 – Результаты исследования

4.3 Исследование № 2. Корректность перевода терминов

4.3.1 Постановка

Для указанных предметных доменов исследовать зависимость доли корректно переведённых терминов от их длины.

Доля корректно переведённых терминов F определена по формуле (4.2):

$$F = \frac{n}{N}, \quad (4.2)$$

где:

- N – число запусков на одних входных данных;
- n – число корректных переводов среди N запусков.

4.3.2 Результаты

Обозначения столбцов:

- F_{Γ} – доля корректных переводов терминов для разработанной графовой языковой модели;
- F_{Π} – доля корректных переводов терминов для нейронной модели GPT-4.

Таблица 4.3 – Результаты исследования № 2. Корректность перевода терминов

Длина термина, шт. слов	ИТ		Строительство		Аэрокосмическая отрасль	
	F_{Γ}	F_{Π}	F_{Γ}	F_{Π}	F_{Γ}	F_{Π}
1	1	0,9	1	0,6	1	0,8
2	1	0,9	1	0,5	1	0,2
3	1	0,7	1	0,1	1	0,2
5	1	0,4	1	0,1	1	0
7	1	0,1	1	0	1	0

На рисунке 4.2 результаты исследования представлены в виде гистограммы.




Рисунок 4.2 – Результаты исследования

4.3.3 Анализ результатов

Вывод

Разработанная графовая модель является полностью детерминированной и выполняет корректный перевод терминов вне зависимости от их длины. Для сравнения, нейронная языковая модель показывает недетерминированный результат, ухудшающийся с ростом длины предложения. Нейронная модель неточно переводит термины узких предметных доменов, с ростом длины переводимого термина частота корректных переводов падает.

ЗАКЛЮЧЕНИЕ

В ходе работы решены следующие задачи:

- 1) введены основные термины и определения задачи машинного перевода, проанализированы существующие методы машинного перевода и программные методы для обработки графовых данных;
- 2) спроектирован метод машинного перевода на основе графовой языковой модели;
- 3) разработано ПО, реализующее спроектированный метод;
- 4) проведено исследование качества результатов разработанного метода для различных предметных доменов.

Разработана графовая языковая модель для решения задачи машинного перевода. Цель выпускной квалификационной работы достигнута

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

1. Global machine translation market [Электронный ресурс]. — Режим доступа: <https://www.mordorintelligence.com/industry-reports/machine-translation-market> (дата обращения: 02.03.2026).
2. How Good Are GPT Models at Machine Translation? A Comprehensive Evaluation [Электронный ресурс]. — Режим доступа: <https://arxiv.org/abs/2302.09210> (дата обращения: 02.03.2026).
3. *Клышинский Э.* Автоматическая обработка текстов на естественном языке и компьютерная лингвистика. — 2017.
4. *Головенко Д.* Особенности и виды машинного перевода // Вестник Московского информационно-технологического университета. — 2020.
5. Natural Language Processing Advancements By Deep Learning: A Survey [Электронный ресурс]. — Режим доступа: <https://arxiv.org/abs/2003.01200> (дата обращения: 29.10.2025).
6. *Прохоров А.* Большой академический словарь. — 2004.
7. Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition, with Language Models [Электронный ресурс]. — Режим доступа: <https://web.stanford.edu/~jurafsky/slp3/> (дата обращения: 29.03.2025).
8. Курс по машинному обучению от Google [Электронный ресурс]. — Режим доступа: <https://developers.google.com/machine-learning/crash-course/embeddings> (дата обращения: 29.10.2025).
9. Документация СУБД Ontotext GraphDB [Электронный ресурс]. — Режим доступа: <https://graphdb.ontotext.com/documentation/10.0/devhub/ontologies.html> (дата обращения: 29.10.2025).
10. Attention is all you need [Электронный ресурс]. — Режим доступа: <https://arxiv.org/abs/1706.03762> (дата обращения: 29.10.2025).
11. Beyond ROUGE: N-Gram Subspace Features for LLM Hallucination Detection [Электронный ресурс]. — Режим доступа: <https://arxiv.org/abs/2509.05360> (дата обращения: 29.10.2025).

12. The cost of training NLP models [Электронный ресурс]. — Режим доступа: <https://arxiv.org/abs/2004.08900> (дата обращения: 29.10.2025).
13. Официальная документация библиотеки NetworkX [Электронный ресурс]. — Режим доступа: <https://networkx.org/documentation/stable/> (дата обращения: 21.05.2026).
14. Официальная документация библиотеки python-igraph [Электронный ресурс]. — Режим доступа: <https://python.igraph.org/en/stable/> (дата обращения: 21.05.2026).
15. Официальная документация библиотеки GraphX [Электронный ресурс]. — Режим доступа: <https://spark.apache.org/docs/latest/graphx-programming-guide.html> (дата обращения: 21.05.2026).
16. Официальная документация библиотеки Deep Graph Library (DGL) [Электронный ресурс]. — Режим доступа: <https://docs.dgl.ai/> (дата обращения: 21.05.2026).
17. Документация СУБД PostgreSQL [Электронный ресурс]. — Режим доступа: <https://www.postgresql.org/docs/> (дата обращения: 29.10.2025).
18. *Клеппман М.* Высоконагруженные приложения. — 2018.
19. Официальная документация библиотеки pgvector [Электронный ресурс]. — Режим доступа: <https://github.com/pgvector/pgvector> (дата обращения: 29.10.2025).
20. Документация СУБД Gel [Электронный ресурс]. — Режим доступа: <https://docs.geldata.com/> (дата обращения: 29.10.2025).
21. Документация СУБД Neo4j [Электронный ресурс]. — Режим доступа: <https://neo4j.com/docs/> (дата обращения: 29.10.2025).
22. Документация СУБД ArangoDB [Электронный ресурс]. — Режим доступа: <https://docs.arango.ai/arangodb/4.0/indexes-and-search/indexing/working-with-indexes/vector-indexes/> (дата обращения: 29.10.2025).
23. Документация СУБД Ontotext GraphDB [Электронный ресурс]. — Режим доступа: <https://graphdb.ontotext.com/documentation/10.0/devhub/ontologies.html> (дата обращения: 29.10.2025).

24. Документация СУБД JanusGraph [Электронный ресурс]. — Режим доступа: <https://docs.janusgraph.org/> (дата обращения: 29.10.2025).
25. Документация СУБД Apache Cassandra [Электронный ресурс]. — Режим доступа: <https://cassandra.apache.org/doc/latest/> (дата обращения: 29.10.2025).
26. Официальная документация библиотеки Gremlin [Электронный ресурс]. — Режим доступа: <https://tinkerpop.apache.org/docs/current/> (дата обращения: 29.10.2025).
27. Официальная документация языка программирования Python [Электронный ресурс]. — Режим доступа: <https://docs.python.org/3/> (дата обращения: 21.05.2026).
28. Документация СУБД Neo4j [Электронный ресурс]. — Режим доступа: <https://neo4j.com/docs/> (дата обращения: 21.05.2026).
29. Официальная документация библиотеки Docker [Электронный ресурс]. — Режим доступа: <https://docs.docker.com/> (дата обращения: 21.05.2026).
30. Официальная документация библиотеки Flask [Электронный ресурс]. — Режим доступа: <https://flask.palletsprojects.com/> (дата обращения: 21.05.2026).
31. Официальная документация библиотеки pymorphy3 [Электронный ресурс]. — Режим доступа: <https://pymorphy2.readthedocs.io/> (дата обращения: 21.05.2026).
32. Официальная документация библиотеки lemmatizer [Электронный ресурс]. — Режим доступа: <https://pypi.org/project/lemmatizer/> (дата обращения: 21.05.2026).
33. Официальная документация библиотеки spaCy [Электронный ресурс]. — Режим доступа: <https://spacy.io/> (дата обращения: 21.05.2026).
34. Официальная документация библиотеки Neo4j Python Driver [Электронный ресурс]. — Режим доступа: <https://neo4j.com/docs/python-manual/current/> (дата обращения: 21.05.2026).

35. Документация языковой модели GPT-4 [Электронный ресурс]. — Режим доступа: <https://developers.openai.com/api/docs/models/gpt-4> (дата обращения: 02.03.2026).
36. *Орлов С.* Англо-русский словарь по вычислительной технике и информационным технологиям. — М.: РадиоСофт, 2020.
37. *Корчемкин С.* Англо-русский строительный словарь. — М.: Рус. Яз., 1995.
38. *Павловец И.* Большой англо-русский и русско-английский словарь авиационных терминов. — М.: Живой язык, 2011.

ПРИЛОЖЕНИЕ А

Диск с рабочими материалами со следующей структурой папок:

report/ - каталог с РПЗ ВКР

app/ - Каталог с исходными кодами

ПРИЛОЖЕНИЕ Б

Презентация к выпускной квалификационной работе состоит из 18 слайдов.