



Министерство науки и высшего образования Российской Федерации
Федеральное государственное автономное образовательное учреждение высшего образования
«Московский государственный технический университет имени Н.Э. Баумана
(национальный исследовательский университет)»
(МГТУ им. Н.Э. Баумана)

Графовая языковая модель для решения задачи машинного перевода

Группа: ИУ7-81Б

Студент: Беляев Никита Александрович

Научный руководитель: Строганов Юрий Владимирович

2026 г.

Цель и задачи.

Цель работы – разработка графовой языковой модели для решения задачи машинного перевода.

Задачи

1. Проанализировать существующие методы машинного перевода.
2. Спроектировать метод машинного перевода на основе графовой языковой модели.
3. Разработать программное обеспечение (ПО), реализующее метод.
4. Исследовать качество разработанного метода для различных предметных доменов.

Рынок решений в области машинного перевода.




Рис 1. Объем рынка машинного перевода.




Рис 2. Доля нейронных моделей машинного перевода




Рис 3. Процент корректных переводов нейронной моделью GPT для различных языковых пар .

Нейронный машинный перевод (МП)
является неточным .

Классификация существующих методов МП.

	МП на основе правил	МП на основе примеров	Статистический МП	Нейронный МП	Предлагаемый метод
Детерминированность	+	+	+	–	+
Отказ при отсутствии данных	+-	+-	–	–	+
Токен	Морфема	Слово / группа слов	Слово / подслово	Подслово	Слово / <u>словосочетание</u>
Структура	Набор правил	Параллельный корпус текстов	Параллельный корпус текстов	Параллельный корпус текстов	Семантические сети
Вычислительная трудоемкость наполнения данными	Низкая	Средняя	Средняя	Высокая	Низкая
Трудоемкость подготовки данных человеком	Высокая	Средняя	Средняя	Низкая	Высокая

Формализованная постановка задачи.

SVO (Subject Verb Object) грамматика

Входное предложение должно иметь структуру вида: “Субъект-Действие-Объект”


Примеры

The epoll instance **monitors** **file descriptor** in the interest list.

Экземпляр epoll **отслеживает** **файловый дескриптор** в списке наблюдаемых событий.

Дополнительные ограничения метода:

1. Язык X – английский, язык Y – русский.
2. Ручное наполнение модели.
3. Утвердительное предложение.




Формализованная постановка задачи.

Семантическая сеть.

Семантическая сеть – информационная модель предметной области, представленная в виде ориентированного графа.

Вершина графа – термин

Ребро графа – отношение между терминами



Пример семантической сети.

Графовая языковая модель.
Представление семантической сети.

$U = (V_u, E_u)$ – взвешенный ориентированный граф

Вершина $v \in V_u$ есть кортеж вида (l_u, q_u) , где:

- $l_u \in \Sigma_u$ – токен;
- $q_l \in \{0, 1, 2, \dots\}$ – индекс омонимии.

Ребро $e \in E_u$ есть кортеж вида (v_i, v_j, m, w) , где:

- $v_i, v_j \in V_u$ – вершины, между которыми установлена связь;
- $m \in M$ – метка типа отношения;
- $w(m) \in [0, 1]$ – вес отношения.

Омонимы – отдельные вершины




Рис 1. Пример наполненной семантической сети.

Графовая языковая модель.

Определение семантической близости терминов.

Термины в вершинах v_i, v_j тем ближе семантически, чем меньше стоимость минимального пути от одного до другого в семантической сети.

$$d(v_i, v_j) = \min \sum_{w_k \in P_{i,j}} w_k$$

- $P_{i,j}$ – кортеж ребер, составляющих путь
- w_k – вес k-го ребра

$$d(\text{Node}^0, \text{OS}^0) = 2 \times w(\text{есть}) + 4 \times w(\text{часть})$$




Рис 1. Пример. Путь от вершины Node^0 до OS^0

Графовая языковая модель. Структура.

$$M = (X, Y, R, W)$$

- **X, Y** – семантические сети языка оригинала и перевода соответственно.
- **R** – множество отношений перевода.
- **W** – кортеж весов, соответствующих меткам типов ребер.




Рис 1. Пример наполненной модели

Метод перевода с применением графовой языковой модели.



Алгоритм разбиения предложения на токены.

Пример при максимальной длине термина $N=3$:

Asphalt concrete pavement requires base course.

[asphalt, concrete, pavement, require, base, course]

1. $n=3$:

1.1. [asphalt, concrete, pavement, require, base, course]

1.2. [asphalt concrete pavement, require, base, course]

2. $n=2$:

2.1. [asphalt concrete pavement, require, base, course]


2.2. [asphalt concrete pavement, require, base, course]

3. $n=1$:

3.1 [asphalt concrete pavement, require, base course]

Итого: [asphalt concrete pavement, require, base course]

* Данные токены содержатся в семантической сети X



Алгоритм формирования подстрочного перевода.

Пример.

Вход:

asphalt concrete pavement,

require,


base course

Выход:

асфальтобетонное покрытие,

требовать,

основание дорожной одежды



Снятие омонимии.

Истинная вершина имеет наибольшее значение функции близости N:

$$N(v, C_x) = \sum_{v_j \in C_x} \frac{1}{d(v, v_j) + 1} \quad (1)$$

- C_x – множество вершин, содержащих однозначные контекстные токены.
- v – текущая вершина.
- $d(v, v_j)$ – расстояние между вершинами v и v_j

$$d(v_i, v_j) = \min \sum_{w_k \in P_{i,j}} w_k \quad (2)$$

- $P_{i,j}$ – кортеж ребер, составляющих путь
- w_k – вес k-го ребра





Рис 1. Иллюстрация снятия омонимии токена “root” с контекстом “OS”.

Примеры переводов с помощью разработанного ПО.

	Вход	Выход
1	The kernel authenticates the root	Ядро аутентифицирует суперпользователя
2	Tree has the root	Дерево имеет корень
3	Bugs live on a tree	Насекомые живут на дереве
4	Tree implementation has bugs	Реализация дерева имеет ошибки
5	He creates <u>child</u> with a fork	Он создал <u>ребенка</u> вилкой
6	He creates <u>child process</u> with a fork	Он создал <u>дочерний процесс</u> системным вызовом fork
7	Asphalt concrete pavement requires <u>base course</u>	Асфальтобетонное покрытие требует <u>основания дорожной одежды</u>

Структура ПО.



Исследование детерминированности перевода.



Рис 1. Процент статей в предметном домене среди технических публикаций за 2021–2024г. на платформе Scopus

$$D = \frac{\text{freq}(\text{mode}(Y_1, \dots, Y_N))}{N} - \text{показатель детерминированности.}$$

- N – число опытов на одних входных данных.
- Y_i – результат i -го перевода.
- $\text{mode}()$ – мода.
- $\text{freq}()$ – частота.




Рис 2. Результат исследования. Штрихованные столбцы – разработанный метод, сплошные – нейронная модель GPT-4 .

Исследование доли правильных переводов терминов.



$$F = \frac{n}{N}$$

– доля правильных переводов терминов.

- N – число опытов на одних входных данных.
- n – число правильных переводов.




Рис 1. Процент статей в предметном домене среди технических публикаций за 2021–2024г. на платформе Scopus

Рис 2. Результат исследования. Штрихованные столбцы – разработанный метод, сплошные – нейронная модель GPT-4.

Заключение.

В ходе работы решены следующие задачи :

1. Рассмотрены и сравнены существующие методы машинного перевода.
2. Спроектирован метод машинного перевода на основе графовой языковой модели.
3. Разработано ПО, реализующее метод.
4. Исследовано качество разработанного метода для различных предметных доменов.

Разработана графковая языковая модель для решения задачи машинного перевода. **Цель ВКР достигнута .**

Дальнейшее развитие:

- Поддержка различных языковых пар.
- Разработка и внедрение алгоритма автоматического или полуавтоматического наполнения модели.